

Proyecto de 1er Bimestre

Sistema de Recuperación de Información

Prof. Iván Carrera — Recuperación de Información

Fecha de entrega: **01 de junio de 2026**

Objetivo

Diseñar e implementar un sistema de recuperación de información que permita comparar modelos clásicos y modernos de recuperación. El sistema deberá indexar un corpus textual utilizando un índice invertido para modelos basados en términos, y una base de datos vectorial para recuperación semántica basada en embeddings. El sistema deberá permitir ejecutar consultas de texto libre, mostrar rankings de documentos y evaluar la calidad de los resultados mediante métricas de Recuperación de Información.

Alcance y funcionalidades mínimas

El sistema debe cumplir con los siguientes requerimientos:

a. Construcción del índice

- Leer un corpus de documentos en texto plano.
- Procesamiento básico: tokenización, normalización y remoción de *stopwords*.
- Construcción de un índice invertido que almacene, para cada término, los documentos en los que aparece y su frecuencia.

b. Modelo de recuperación

- Implementar recuperación basada en similitud Jaccard utilizando vectores binarios
- Implementar recuperación basada en similitud de coseno utilizando TF-IDF
- Implementar recuperación con BM25.
- Permitir la ejecución de consultas de texto libre.
- Mostrar un ranking de documentos ordenados por relevancia.

c. Interfaz básica

- Interfaz de línea de comandos (CLI).
- Funcionalidades mínimas:
 - Realizar consultas
 - Visualizar los resultados

d. Recuperación semántica con embeddings

- Generar embeddings para los documentos del corpus utilizando un modelo preentrenado.
- Generar embeddings para las consultas de texto libre.
- Almacenar los embeddings en una base de datos vectorial, como **ChromaDB** o **FAISS**.
- Recuperar los documentos más similares usando búsqueda vectorial.

- Mostrar un ranking de resultados basado en similitud vectorial.

e. Evaluación de resultados

- Usar un conjunto de consultas de prueba y documentos relevantes (*qrels*).
- Calcular para cada consulta:
 - *Precision*
 - *Recall*
- Calcular para todo el sistema:
 - MAP

f. Comparación de modelos

- Comparar los resultados obtenidos con:
 - Modelo binario con similitud Jaccard.
 - Modelo vectorial con TF-IDF y similitud coseno.
 - BM25.
 - Recuperación semántica con embeddings y base vectorial.
- Analizar en qué tipos de consultas funciona mejor cada modelo.
- Identificar casos donde la recuperación semántica mejora o empeora respecto a BM25 o TF-IDF.

Requisitos técnicos

- Lenguaje sugerido: Python.
- Se pueden usar bibliotecas como NumPy, pandas, NLTK, spaCy, scikit-learn, sentence-transformers.
- Para recuperación vectorial se debe usar ChromaDB o FAISS.
- No se permite el uso de motores completos de búsqueda como Elasticsearch, Solr o Whoosh.
- La implementación de los modelos clásicos debe ser propia o claramente explicada.

Entregables

1. Código fuente con instrucciones claras de ejecución (README).
2. Informe técnico (máximo 5 páginas), que incluya:
 - Descripción del corpus utilizado.
 - Explicación de las decisiones de diseño.
 - Ejemplos de consultas y resultados.
 - Análisis de métricas de evaluación.